

blatt8 (2)

June 27, 2024

Blatt 08 - Praktische Optimierung - Adrian Lentz, Robert Schönewald

Lösungen und Erklärungen für Blatt 08.

Adrian Lentz - Matrikelnummer: 258882

Robert Schönewald - Matrikelnummer: 188252

```
[1]: import numpy as np
import matplotlib.pyplot as plt
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import PolynomialFeatures
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error, mean_squared_error
from gplearn.genetic import SymbolicRegressor

np.random.seed(0)
```

```
-----
ModuleNotFoundError                                Traceback (most recent call last)
Cell In[1], line 7
      5 from sklearn.linear_model import LinearRegression
      6 from sklearn.metrics import mean_absolute_error, mean_squared_error
----> 7 from gplearn.genetic import SymbolicRegressor
      9 np.random.seed(0)

ModuleNotFoundError: No module named 'gplearn'
```

Teil a

```
[5]: def true_fun(x):
      return 10 - x * np.cos(x)

LOWER = -10
UPPER = 10
```


```

N_Samples = 11
X_samples=np.linspace(LOWER,UPPER,N_Samples)
y_samples=true_fun(X_samples)

X = np.linspace(LOWER, UPPER, 201) #201 äquidistante Stellen
plt.plot(X, true_fun(X), label="True function")
plt.xlabel("$x$")
plt.ylabel("$f(x)$")

plt.show()

```



Polynomial Modell

```

[3]: def make_poly_model(f, k, X_samples, y_samples):
    # Erstellung der Polynomialfeatures und Lineare Regression
    polynomial_features = PolynomialFeatures(degree=k, include_bias=True)
    linear_regression = LinearRegression()
    pipe = Pipeline(
        [
            ("polynomial_features", polynomial_features),

```

```

        ("linear_regression", linear_regression),
    ]
)
# Modell an den gegebenen Samples fitten
pipe.fit(X_samples.reshape(-1,1), y_samples.reshape(-1,1))

return lambda x: pipe.predict(np.array(x).reshape(-1,1)).flatten()

#Test
pred_fun = make_poly_model(true_fun, k=1) #k=1,2,5,10,15
pred_fun(1)

```

```

[4]: degrees = [1,2,5,10,15] #k=1,2,5,10,15
NUM_OF_REPEATS = 1

pred_funcs = {}
for degree in degrees:
    pred_funcs[degree]=[]
    for _ in range(NUM_OF_REPEATS):
        pred_funcs[degree].append(make_poly_model(true_fun, k=degree,
↪X_samples=X_samples, y_samples=y_samples))

```

```

[5]: fig = plt.figure(figsize=(8, 8))

true_y = true_fun(X)
mean_y_k, vars_y_k = {}, {}

mse_scores, mae_scores = {}, {}

for idx, degree in enumerate(degrees):
    plt.subplot(5,1,idx+1)

    # plot predicted functions
    pred_y = np.zeros((NUM_OF_REPEATS, len(X)))

    for i, pred_f in enumerate(pred_funcs[degree]):
        pred_y[i] = pred_f(X)
        plt.plot(X, pred_y[i], c="gray")#, label="Predicted function")

    # calculate mean and variance
    mean_y_k[degree] = np.mean(pred_y, axis=0)
    vars_y_k[degree] = np.var(pred_y, axis=0)

    # calculate MAE and MSE
    mae_scores[degree] = mean_absolute_error(true_y, mean_y_k[degree])
    mse_scores[degree] = mean_squared_error(true_y, mean_y_k[degree])

```

```

# plot mean prediction
plt.plot(X, mean_y_k[degree], color="red", label="Prediction mean"\
         if degree == degrees[0] else None)


# plot true function
plt.plot(X, true_y, color="orange", label="True function"\
         if degree == degrees[0] else None)

plt.xlabel("$x$")
plt.ylabel("$f(x)$")
plt.xlim((LOWER, UPPER))
plt.ylim((-30,30))
plt.title(f"Degree $k={degree}$\nMAE: {mae_scores[degree]:.2f}, MSE: \
↪{mse_scores[degree]:.2f}")

fig.legend(loc='lower center', bbox_to_anchor=(0.54, -0.025), ncol=2)

plt.tight_layout()
plt.show()

```



Werte des MSE können sehr stark variieren, da MSE sehr empfindlich gegenüber Ausreißern ist. MAE (absolute Fehler) ist relativ robust, da nur absoluten Fehler betrachtet \rightarrow Außer für $k=15$.

```
[6]: for degree in [10, 15]:
    errors = np.abs(mean_y_k[degree] - true_y)
    squared_errors = (mean_y_k[degree] - true_y) ** 2

    print(f"Degree {degree}:")
    print(f"Max Absolute Fehler: {np.max(errors):.2f}")
    print(f"Max Squared Fehler: {np.max(squared_errors):.2f}")


plt.figure(figsize=(10, 5))
```

```
plt.plot(X, errors, label="Absolute Fehler")
plt.plot(X, squared_errors, label="Squared Fehler")
plt.xlabel("$x$")
plt.ylabel("Fehler")
plt.title(f"Fehler Analyse für Degree {degree}")
plt.legend()
plt.show()
```

Degree 10:

Max Absolute Fehler: 15.33


Max Squared Fehler: 235.16



Degree 15:

Max Absolute Fehler: 17795.83

Max Squared Fehler: 316691515.42



Man erkennt das die größten Fehler in den Randbereichen des Definitionsbereich von x auftreten, wobei insbesondere für $k=10$ der absolute Fehler noch stark ist, für $k=15$ sind die Fehler noch deutlich größer, sodass in der Abbildung die Fehler-Skalierung deutlich größer ist ! Sowohl der absolute und der quadratische Fehler sind für $k=15$ sehr groß.

Kriging

```
[2]: from sklearn.gaussian_process import GaussianProcessRegressor
      from sklearn.gaussian_process.kernels import RBF, Matern, ExpSineSquared
```

```
[3]: 'Kernels'
      kernels = [
          RBF(), #Radiale Basisfunktion
          Matern(nu=0.5), #matern Kernel
          Matern(nu=1.5),
          Matern(nu=2.5),
          ExpSineSquared(periodicity=4), #Exp-sin-Square Kernel
          ExpSineSquared(periodicity=6),
          ExpSineSquared(periodicity=8)
      ]
```

```
[6]: 'Test-Punkte'
      X_test = np.linspace(-10, 10, 201).reshape(-1, 1) # 201 Punkte
      y_test = true_fun(X_test)

      X_train = np.linspace(-10, 10, 11).reshape(-1, 1) # 11 äquidistante Punkte
```

```
y_train = true_fun(X_train).ravel() # Funktion an den Trainingspunkten  
↳ auswerten
```

[7]: 'Graphische Darstellung der verschiedenen Kernels'


```
plt.figure(figsize=(14, 10))  
plt.plot(X_test, y_test, 'k', label='True function')  
  
for kernel in kernels:  
    # Modell initialisieren  
    gpr = GaussianProcessRegressor(kernel=kernel)  
    # Modell an Trainingsdaten anpassen  
    gpr.fit(X_train, y_train)  
    # Vorhersagen machen  
    y_pred, sigma = gpr.predict(X_test, return_std=True)  
    # Ergebnisse plotten  
    plt.plot(X_test, y_pred, label=f'Kernel: {kernel}')  
    plt.fill_between(X_test.ravel(), y_pred - sigma, y_pred + sigma, alpha=0.1)  
  
plt.scatter(X_train, y_train, c='r', marker='x', label='Trainingsdaten')  
plt.title('Gaussian Process Regression mit verschiedenen Kernels')  
plt.xlabel('x')  
plt.ylabel('f1(x)')  
plt.legend()  
plt.show()
```

```
c:\Users\Adria\AppData\Local\Programs\Python\Python312\Lib\site-  
packages\sklearn\gaussian_process\kernels.py:445: ConvergenceWarning: The  
optimal value found for dimension 0 of parameter length_scale is close to the  
specified lower bound 1e-05. Decreasing the bound and calling fit again may find  
a better value.
```

```
warnings.warn(  
c:\Users\Adria\AppData\Local\Programs\Python\Python312\Lib\site-  
packages\sklearn\gaussian_process\kernels.py:455: ConvergenceWarning: The  
optimal value found for dimension 0 of parameter periodicity is close to the  
specified upper bound 100000.0. Increasing the bound and calling fit again may  
find a better value.
```

```
warnings.warn(  

```

Man erkennt die deutlichen Unterschiede zwischen den verschiedenen verwendeten Kernel Varianten:

Der Exp-Sin-Kernel sind zwei der drei Varianten ($p=4,6$) (braun, violett) sehr schlecht, in Bezug auf die Funktion (schwarz).

Die Kernel Varianten der radialen Basisfunktionen und des Matern Kernel erzeugen visuell gute Ergebnisse, wobei keine direkten Unterschiede klar zu erkennen sind.

Um eine bessere Bewertung vorzunehmen, werden anschließend die mittlere absolute Abweichung und die mittlere quadratische Abweichung betrachtet, wodurch auch ein Vergleich zum Polynomiellen Modell möglich ist.

```
[8]: results = {}

# Gaussian Process Modelle trainieren, vorhersagen und Abweichungen berechnen
for kernel in kernels:
    gpr = GaussianProcessRegressor(kernel=kernel)
    gpr.fit(X_train, y_train)
    y_pred, sigma = gpr.predict(X_test, return_std=True)

    mae = mean_absolute_error(y_test, y_pred)
    mse = mean_squared_error(y_test, y_pred)
```

```
results[str(kernel)] = {'MAE': mae, 'MSE': mse}
print(f'Kernel: {kernel}\nMAE: {mae:.4f}\nMSE: {mse:.4f}\n')
```

Kernel: RBF(length_scale=1)

MAE: 0.4110

MSE: 0.4527

Kernel: Matern(length_scale=1, nu=0.5)

MAE: 1.2263

MSE: 2.7305

Kernel: Matern(length_scale=1, nu=1.5)

MAE: 0.7384

MSE: 1.0662

Kernel: Matern(length_scale=1, nu=2.5)

MAE: 0.6098

MSE: 0.7885

Kernel: ExpSineSquared(length_scale=1, periodicity=4)

MAE: 7.9667

MSE: 88.7055

Kernel: ExpSineSquared(length_scale=1, periodicity=6)

MAE: 3.4577

MSE: 18.1311

Kernel: ExpSineSquared(length_scale=1, periodicity=8)

MAE: 0.4122

MSE: 0.4359

c:\Users\Adria\AppData\Local\Programs\Python\Python312\Lib\site-packages\sklearn\gaussian_process\kernels.py:445: ConvergenceWarning: The optimal value found for dimension 0 of parameter length_scale is close to the specified lower bound 1e-05. Decreasing the bound and calling fit again may find a better value.

```
warnings.warn(
```

c:\Users\Adria\AppData\Local\Programs\Python\Python312\Lib\site-packages\sklearn\gaussian_process\kernels.py:455: ConvergenceWarning: The optimal value found for dimension 0 of parameter periodicity is close to the specified upper bound 100000.0. Increasing the bound and calling fit again may find a better value.

```
warnings.warn(
```

```
[9]: #Bestes/Schlechtetes Modell
best_kernel = min(results, key=lambda k: results[k]['MAE'])
worst_kernel = max(results, key=lambda k: results[k]['MAE'])
print(f'Bestes Modell basierend auf MAE: {best_kernel} mit MAE:␣
↪{results[best_kernel]["MAE"]:.4f} und MSE: {results[best_kernel]["MSE"]:.
↪4f}')
print(f'Schlechtestes Modell basierend auf MAE: {worst_kernel} mit MAE:␣
↪{results[worst_kernel]["MAE"]:.4f} und MSE: {results[worst_kernel]["MSE"]:.
↪4f}')
```

Bestes Modell basierend auf MAE: RBF(length_scale=1) mit MAE: 0.4110 und MSE: 0.4527

Schlechtestes Modell basierend auf MAE: ExpSineSquared(length_scale=1, periodicity=4) mit MAE: 7.9667 und MSE: 88.7055

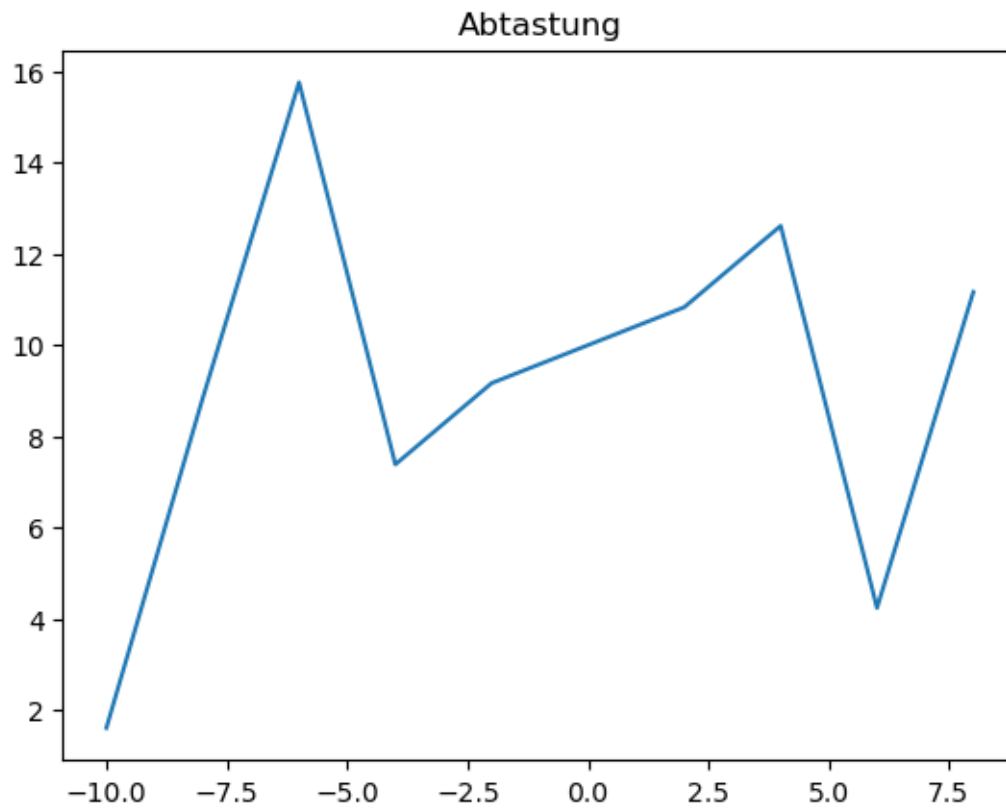
Durch die Betrachtung der mittleren Abweichung bestätigt sich die visuelle Vermutung, der radiale Basisfunktion Kernel schneidet am besten ab, hingegen der Exp-Sin Kernel mit $p=4$ am schlechtesten ist.

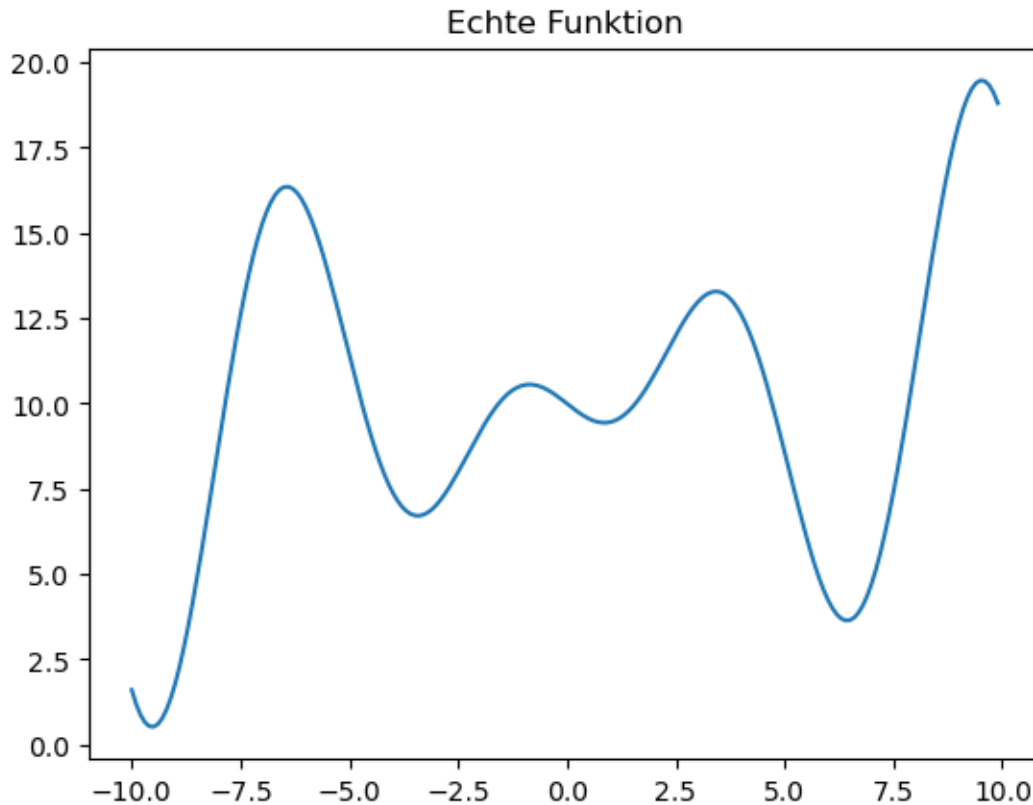
Symbolische Regression

```
[7]: #ergebnisse=[[3.412096883468112, 3.411384119292495, 3.41139416429113, 3.
↪4144380500707427, 3.411589962370803, 3.411587573085578, 3.4123197802444296,␣
↪3.4123357068377245, 3.4123352027972116, 3.412225816492165], [3.
↪4310083553729425, 3.4461772054621775, 4.210850094556318, 3.4212849478562743,␣
↪3.4298376076071366, 3.4150936225491986, 3.438618800945967, 4.
↪229564625033519, 3.4233138889140546, 3.426234728198251], [2.569084276409377,␣
↪2.8461268152512726, 2.258520156416018, 2.83783902426103, 2.355779892079767,␣
↪2.1871537902850764, 2.483166645039068, 2.84198989547309, 2.8443472199543574,␣
↪2.847968630694601], [1.4467140095101552, 1.86489255061835, 2.
↪0769625127102262, 1.4455295143448579, 1.9123484317260617, 2.845316719842962,␣
↪1.8200045343759148, 1.8347978900227104, 2.206795898552612, 1.
↪1770640989925316], [9.000275539865292, 9.000322938444684, 9.000000271636575,␣
↪9.000026453618377, 9.000003017806371, 9.000010814467721, 9.000038031606294,␣
↪9.000035861688184, 9.0000000000000002, 9.000041930961835], [2.
↪539735054230188, 0.4623621105103869, 3.2901547421202135, 0.8555423450398368,␣
↪0.995499502819521, 0.3552372235707458, 1.0729669018864543, 0.
↪8366159474659685, 0.4851271015154591, 2.7966886810863514], [0.
↪005132790373879794, 0.42489035092205135, 1.042522364710662, 0.
↪0022239493565253776, 0.06468732111599763, 0.5306720506911966, 0.
↪8386968462634403, 0.5318964825241479, 0.5162446806195534, 0.
↪1522034794703366], [1.5678714477165008, 0.23583224526432112, 0.
↪6925482369724189, 0.12969092310827274, 1.6591612681054635, 0.
↪011107242097641872, 1.133814469470137, 1.5571159174176648, 1.
↪9032059512600894, 0.20470373065054973]]
```

```
[9]: x = np.arange(-10, 10, 2)
x_fine=np.arange(-10, 10, 0.1)
y_truth = 10 - x * np.cos(x)

ax = plt.figure().add_subplot()
plt.plot(x, y_truth)
plt.title("Abtastung")
ax = plt.figure().add_subplot()
plt.plot(x_fine, true_fun(x_fine))
plt.title("Echte Funktion")
plt.show()
```





[10]:

```
# Training samples
X_train = np.arange(-10, 11, 2).reshape(11, 1)
y_train = 10 - X_train * np.cos(X_train)

# Testing samples
X_test = np.arange(-10, 10.1, 0.1).reshape(201, 1)
y_test = 10 - X_test * np.cos(X_test)
```

[11]:

```
combs=[('add','sub'),('mul','div'),('add','mul'),('add','sub','mul','div'),('sin','cos'),('add',
ergebnisse=[]
best_gp= SymbolicRegressor(population_size=500, generations=25,
    ↳stopping_criteria=0.
    ↳01,verbose=0,function_set=('sub','mul','cos'),n_jobs=-1,tournament_size=10)
best_gp.fit(X_samples.reshape(-1, 1),y_samples)
for y in combs:
    einzelergebnisse=[]
    for x in range(10):
        est_gp = SymbolicRegressor(population_size=500, generations=25,
    ↳stopping_criteria=0.01,verbose=0,function_set=y,n_jobs=-1,tournament_size=10)
        est_gp.fit(X_samples.reshape(-1, 1),y_samples)
        #print(est_gp._program.raw_fitness_)
```

```

    einzelergebnisse.append(est_gp._program.raw_fitness_)
    if est_gp._program.raw_fitness_ < best_gp._program.raw_fitness_:
        best_gp=est_gp
    ergebnisse.append(einzelergebnisse)
print(ergebnisse)

```

```

[[3.411708619911212, 3.411531942513665, 3.4136023305596854, 3.4113964343585277,
3.411880289400983, 3.4124747061813423, 3.4121998291115987, 3.413364997392431,
3.411383898561421, 3.4116094848917013], [3.4153887674049845, 3.442384873536167,
3.4352134078684458, 3.414670145568456, 3.418920173232552, 3.5116320663681746,
3.4200534511109066, 3.4384275561038447, 3.4285766773368405, 3.4256793102084613],
[2.5723045122523973, 2.4280957416247513, 2.8564893337084247, 2.0277275456189163,
2.5361553977047144, 2.1356172803477236, 2.4947945165883922, 2.8418208239116867,
2.840672689295354, 2.3334363609686735], [1.5834125062464546, 2.51416616946715,
1.5097457699292258, 1.912848739555438, 2.349282325314984, 2.569750667191023,
2.0330740100516724, 2.0884158278891283, 1.1625828561599494, 1.9603730747778376],
[9.000005826805717, 9.000020684957786, 9.000051603009597, 9.000191336049134,
9.00004653311491, 9.000284307540108, 9.000009706278716, 9.000090796556465,
9.000012739565573, 9.000014034029956], [1.2767647113027072, 1.0862220481072755,
0.7677375947234069, 0.4832962361945347, 2.0645736736711084, 0.8801010094542672,
2.692766826548169, 0.734351593860925, 0.5594217941791109, 0.9745929500890579],
[0.0044192284898730335, 3.225095038688131, 0.2124658990998437,
0.019967904852415085, 0.00985381334777627, 2.071343789266626,
0.16909248279849365, 0.02987107811987869, 1.5039750904085503,
0.008688813248628267], [1.6126705722605104, 0.0474263866686591,
1.193224551301183, 0.4847290482066993, 1.297089833353825, 1.995552122142604,
1.0509625274290444, 1.1574105051161332, 0.41939507207302357,
0.2916669267763741]]

```

Funktion der Parameter:

Populationsgröße:

Das ist die Anzahl von Programmen, die sich in einer Generation befinden.

Turniergröße:

Die Anzahl an Programmen, die gegeneinander antreten, um Teil der nächsten Generation zu sein.

Generationsanzahl:

Wie viele Generationen durchlaufen werden, bevor gestoppt wird.

Stoppkriterium:

Falls vor Ende des Generationslimits ein bestimmter Wert erreicht wird, wird gestoppt.

```


[12]: fig, ax = plt.subplots()
      ax.boxplot(ergebnisse)
      ax.set_xticklabels(['+ -', ('* /'), ('+ *'), ('+ - * /'), ('sin cos'), ('+ * sin'), ('- * cos'), ('alle')])
      ax.set(xlabel='Kombinationen', ylabel='Fitness')

```

```

[12]: [Text(0.5, 0, 'Kombinationen'), Text(0, 0.5, 'Fitness')]

```




Es scheint die Kombination “- * cos” konstant die beste Fitness zu erreichen.

```
[13]: print(best_gp._program)
```

```
sub(cos(cos(cos(mul(0.922, -0.248)))), sub(sub(sub(sub(0.122, sub(cos(0.740),
sub(mul(-0.505, sub(cos(-0.022), sub(X0, X0)))), sub(sub(sub(0.809, -0.298),
mul(X0, cos(X0))), sub(0.610, 0.793))))), sub(cos(cos(mul(0.922, -0.248))),
sub(sub(sub(sub(sub(sub(cos(-0.148), cos(-0.555)), cos(mul(cos(-0.793),
cos(-0.148)))), 0.793), sub(sub(0.928, X0), sub(-0.708, X0))),
cos(cos(mul(-0.058, 0.772)))), 0.740))), cos(sub(X0, X0))),
cos(cos(cos(mul(0.922, -0.248)))))
```

```
[16]: y_gp = best_gp.predict(np.c_[x_fine.ravel()]).reshape(x_fine.shape)
score_gp = best_gp.score(X_test, y_test)
fig = plt.figure(figsize=(12, 10))

ax = fig.add_subplot(1, 1, 1)
plt.plot(x_fine, y_gp)
plt.plot(x_fine, true_fun(x_fine))
points = ax.scatter(X_train, y_train)
plt.title("SymbolicRegressor")
plt.show()
```



Beide Kurven überdecken sich, man kann vermuten, dass die Abweichungen sehr gering sein werden.

```
[22]: yAbw=true_fun(x_fine)
      absAbw=np.sum(np.abs(yAbw-y_gp))/201
      print(absAbw)
      quaAbw=np.sum((yAbw-y_gp)**2)/201
      print(quaAbw)
```

```
0.004397242278481326
1.9432418353941956e-05
```

Vergleich der Abweichung

Das polynomielle Modell zeigt eine maximale Abweichung von Max Absolute Fehler: 17795.83 ; Max Squared Fehler: 316691515.42, welches besonders groß sind. Jedoch ist die minimale Abweichung für ein Polynom mit Grad $k=5$ nur MAE:2,38 und ein MSE: 8,66.

Das Kriging Modell zeigt eine maximale Abweichung von ExpSineSquared(length_scale=1, periodicity=4) mit MAE: 7.9667 und MSE: 88.7055. Die minimale Abweichung ergibt sich für die radiale

Basisfunktion mit MAE: 0.4110 und MSE: 0.4527.

Die Symbolische Regression zeigt eine maximale Abweichung von MAE:0.004397242278481326 und MSE: 1.9432418353941956e-05.

Im gesamten Vergleich ist somit die symbolische Regression am besten geeignet, jedoch liefert auch das Kriging Modell mit einer radialen Basisfunktion, eine relativ gute Abbildung der Funktion.


Teil b

Symbolische Regression


```
[2]: def true_fun2(x):  
      return 5*np.minimum(x[0],x[1]) - 3 * x[0]
```

```
[19]: x0 = np.arange(0, 100, 1)  
      x1 = np.random.normal(50, 7, 100)  
      x0, x1 = np.meshgrid(x0, x1)  
      y_truth = 5*np.minimum(x0,x1) - 3 * x0  
  
      x0_fine=np.arange(0, 100, 1)  
      x1_fine=np.arange(30, 70, 1)  
      x0_fine, x1_fine = np.meshgrid(x0_fine, x1_fine)  
      y_truth_fine = 5*np.minimum(x0_fine,x1_fine) - 3 * x0_fine  
  
      ax = plt.figure().add_subplot(projection='3d')  
      surf = ax.plot_surface(x0, x1, y_truth, rstride=1, cstride=1,  
                             color='green', alpha=0.5)  
      plt.title("Abtastung")  
      plt.show()  
      ax = plt.figure().add_subplot(projection='3d')  
      surf = ax.plot_surface(x0_fine, x1_fine, y_truth_fine, rstride=1, cstride=1,  
                             color='green', alpha=0.5)  
      plt.title("Wahre Funktion")  
      plt.show()
```

Abtastung



Wahre Funktion



```
[64]: # Training samples
a=[]
b=[]
for j in range (100):
    k=np.random.normal(50, 7)
    for i in range(101):
        a.append(i)
        b.append(k)
X_train=np.stack([a,b],axis=1)
print(X_train)
y_train = 5*np.minimum(X_train[:, 0],X_train[:, 1]) - 3 * X_train[:, 0]
```

```
[[ 0.          37.22853389]
 [ 1.          37.22853389]
 [ 2.          37.22853389]
 ...
 [ 98.         53.69217396]
 [ 99.         53.69217396]
 [100.         53.69217396]]
```

```
[66]: est_gp = SymbolicRegressor(population_size=1000, generations=25,
    ↪stopping_criteria=0.
    ↪01,verbose=1,function_set=('min','mul','min'),n_jobs=-1,tournament_size=10)
est_gp.fit(X_train, y_train)
```

Population Average			Best Individual			
Gen	Length	Fitness	Length	Fitness	OOB Fitness	Time
Left						
0	38.93	3.89979e+12	15	31.8957	N/A	
1.27m						
1	19.61	2.20773e+07	15	31.8957	N/A	
15.00s						
2	11.31	27390.1	47	30.3462	N/A	
16.65s						
3	13.78	170531	51	29.9901	N/A	
18.21s						
4	14.00	6765.7	55	29.9901	N/A	
18.54s						
5	24.63	45414.4	55	29.1404	N/A	
18.60s						
6	46.01	573908	45	28.3967	N/A	
19.24s						
7	52.41	1.29288e+08	43	28.3967	N/A	

20.01s					
8	56.77	11982.2	31	28.3967	N/A
18.77s					
9	52.91	127387	47	28.3967	N/A
29.55s					
10	47.50	147611	57	28.3967	N/A
16.28s					
11	39.60	56495.1	59	28.3967	N/A
14.22s					
12	30.51	11962	53	28.3967	N/A
13.67s					
13	23.83	64509.4	63	28.3967	N/A
11.34s					
14	20.82	48525.9	15	28.3967	N/A
9.98s					
15	17.79	19651.8	25	28.3967	N/A
8.80s					
16	16.73	643303	15	28.3967	N/A
7.66s					
17	15.87	77391.7	15	28.3967	N/A
6.59s					
18	15.47	2.30984e+06	21	28.3967	N/A
5.50s					
19	13.99	7242.1	11	28.3967	N/A
4.36s					
20	12.74	10152.4	11	28.3967	N/A
3.55s					
21	11.87	21745	11	28.3967	N/A
2.33s					
22	11.73	11332.8	15	28.3967	N/A
1.62s					
23	11.50	13418.1	11	28.3967	N/A
0.83s					
24	11.32	619636	11	28.3967	N/A
0.00s					

```
[66]: SymbolicRegressor(function_set=('min', 'mul', 'min'), generations=25, n_jobs=-1,
      stopping_criteria=0.01, tournament_size=10, verbose=1)
```

```
[67]: print(est_gp._program)
```


```
min(X1, mul(mul(X0, X1), mul(mul(-0.592, -0.232), 0.273)))
```

```
[68]: x0 = np.arange(0, 100, 1)
      x1 = np.arange(40, 70, 1)
      x0, x1 = np.meshgrid(x0, x1)
      y_gp = est_gp.predict(np.c_[x0.ravel(), x1.ravel()]).reshape(x0.shape)
      fig = plt.figure(figsize=(12, 10))
```

```

ax = fig.add_subplot(2, 2, 1, projection='3d')
surf = ax.plot_surface(x0, x1, y_gp, rstride=1, cstride=1, color='green',
    ↪alpha=0.5)
points = ax.scatter(X_train[:, 0], X_train[:, 1], y_train)
plt.show()

```



```

[76]: yAbw=true_fun2([x0,x1])
absAbw=np.sum(np.abs(yAbw-y_gp))/4141
print(absAbw)
quaAbw=np.sum((yAbw-y_gp)**2)/4141
print(quaAbw)

```

```

19.22553588632645
1008.7567837194632

```

Im Gegensatz zu dem 2D Fall entstehen hier deutlich größere Fehler

```
[ ]:
```